

Agent 平替 v0.1 —— 短名单 + 路由建议

- 你在看：v0.1 结果报告 —— 套上达标线后的短名单 + per-task 路由 + 混合省钱率
- 上游：v0 结果报告 —— 质量 × 成本表（跑完之后的结果）
- 底表：per-task 矩阵 CSV —— 18×4（score + token + \$），本报告所有数字的来源
- 证据：run-log · bug 写报：findings
- 达标线：Paul 锁定 质量 ≥ 70% / 成本 ≤ ½（起步值，见 DECISIONS）
- 口径：common-14 公共题集，与 v0 主表一致、跨模型可比
- 数字：均已对底表逐项重算、可回溯

0. 结论

在 Paul 锁定的达标线（质量 ≥ 70% / 成本 ≤ ½）下，便宜模型短名单 = 仅 GLM-4.6。但真正的产品结论不在「换不换 GLM」，而在怎么路由：

- 纯换 GLM（不路由）= 76% 质量 / 省 8.4x；
- 按题路由（难题回退 Claude）= 99% 质量 / 省 ~2x。

后者几乎不丢质量、成本仍砍一半，且正落在 Paul 设的 ≤½ 线上——这就是 hybrid 路由要交付的甜区，也是 v0.1 把「能不能替」推进到「怎么替最划算」的一步。

1. 短名单：套达标线（common-14）

模型	质量	=Claude	\$/题	=Claude 成本	便宜	过线?
Claude sonnet-4.6	0.653	100%	\$0.439	1.00	1x	基准
GLM-4.6	0.497	76%	\$0.052	0.12	8.4x	✅ 进短名单
DeepSeek V3.2	0.433	66%	\$0.162	0.37	2.7x	❌ 质量不过
Qwen3-Coder	0.377	58%	\$0.209	0.48	2.1x	❌ 质量不过

质量是唯一筛子。DeepSeek / Qwen 的成本其实都已 ≤½，被卡的全在 70% 质量线——所以这条线下短名单干净（只有 GLM），对外最好讲：纯按质量筛掉，没有靠成本门槛硬卡。

2. Per-task 分档：14 题里 10 道走 GLM、4 道留 Claude

逐题比 GLM 与 Claude（门槛：该题 GLM ≥ 70% × Claude）：

- 🟢 GLM-safe x10 —— GLM 达标，直接走便宜。含 financial_stmt、pe_screening、os_log、tcga（多数 100%+），以及 k8s、homework、agora 等。
- 🔴 Claude-only x4 —— GLM 明显做不出，留 Claude：

- causal_ihdp_ite_estimation (Claude 0.178 / GLM 0.000)
- crf_sdtm_mapping (0.589 / 0.000)
- molecular_structure_plausibility (0.500 / 0.167)
- capacitated_vehicle_routing (1.000 / 0.000)

含义：路由不是「整体换 GLM」，是「按题分流」——这 10/4 的切分就是路由策略表的雏形。

3. 混合省钱曲线 ☆（核心结论）

策略	质量	=Claude	\$/题	便宜
全 Claude（基准）	0.653	100%	\$0.439	1×
纯 GLM（不路由）	0.497	76%	\$0.052	8.4×
Per-task 混合 / verify 兜底	0.647	99%	~\$0.22	~2×

一句话：纯换 GLM 丢掉 24% 质量换 8.4× 便宜；按题路由只丢 1% 质量，仍省 ~2×——难题回退 Claude，几乎不丢质量、成本砍半。而且这个混合点正落在 Paul 设的 $\leq \frac{1}{2}$ 成本线上（0.5× cost / 99% 质量），说明他这条起步线在 per-task 混合下是可达的甜区，不是空设。

路由机制：便宜模型先跑 → 自动判分 → 没过回退 Claude（verify-then-route）。质量与 oracle 分流持平（0.647），成本略高（\$0.22，因为回退题付了两遍）。

4. 局限（必须如实标注）

- 「99% / 2×」是可达上界，不是生产实测。它是在 ALE 14 题上、用真实判分器模拟分流得到的；生产里没有现成判分器，实际落点取决于「分类器 + verify 代理」的准确度——会落在「纯 GLM 76%」与「上界 99%」之间。
- 样本小：common-14；趋势可信，绝对值待更大 N 收敛。
- 边角：epidemiology_forecast 两个模型都 0 分，被归入 GLM-safe（都失败→走便宜不丢质量），属正常处理、已知悉。
- 分布：仍是 ALE 公开基准，≠ BFC 真实流量；最终要真实流量数据接力。

5. 下一步（谁做什么）

SDE（用底表起路由，部分不卡门槛、可即刻开工）：– ① 用 per-task 矩阵 CSV 复跑 §2 分档 + §3 曲线（脚本逻辑已 audit）；– ② 原型 verify-then-route 运行时机制（便宜先跑 → 判分 → 没过回退）——这是兜底层，不依赖门槛；– ③ 起草 lightweight 分类器方案（prompt → 任务类型 + 难度），带置信度、低置信默认留 Claude。

Elena（PM）：– ① 本报告 + 套表交付；② 扩 N / 加 Windows·GPU 题降噪；③ Kimi 直连原生端点重测。

Paul: $\leq \frac{1}{2}$ 是起步值——等 §3 的真实 blended 省钱率在更大 N 上稳了，再决定是否收紧（保守）或维持。

Han / Abby: Han 确认 per-run 判分口径 + 私有题库可用范围；Abby 提供各模型官方计费价核对、线上成败信号为真实流量阶段铺路。

数据与全程证据: repo `agent-eval-v0` (底表 *CSV* / *run-log* / *findings*)。达标线决策见 *DECISIONS*。

Repo: <https://github.com/yingshill/agent-eval-v0>